



自然語言處理與文字探勘

陳縉農 & 教研處

「版權聲明頁」

本投影片已經獲得作者授權台灣人工智慧學校得以使用於教學用途，如需取得重製權以及公開傳輸權需要透過台灣人工智慧學校取得著作人同意；如果需要修改本投影片著作，則需要取得改作權；另外，如果有需要以光碟或紙本等實體的方式傳播，則需要取得人工智慧學校散佈權。

課程內容

[講師投影片](#)

[資料與投影片](#)

[影片播放列表](#)

程式碼: ~/courses-tpe/NLP

1. 文本特徵建模練習
2. NLP with RNN
3. BERT fine-tune

Code / Data 放在 hub 中的 courses 內

- 為維護課程資料，courses 中的檔案皆為 read-only, 如需修改請 cp 至自身的環境中
- 打開 terminal, 輸入
 - [台北班]
`cp -r courses-tpe/NLP/part4 <存放至本機的名稱>`
 - [新竹班]
`cp -r courses-hsi/NLP/part4 <存放至本機的名稱>`
 - [台中班]
`cp -r courses-txg/NLP/part4 <存放至本機的名稱>`



程式實作

文本特徵建模練習

程式練習時間

- 06_predict.ipynb
 - 定義 y : 發文的推文多 or 噓文多 ?
 - 絕對差異定義 ? > 20
 - 利用 bag of words, TF-IDF, average word2vec, doc2vec 各做一組 prediction model, 比較哪一組 features 最好



程式解說

```
localhost:8888/localhost/data_dir/server/review/06_predict.ipynb
jupyter 06_predict (python3)
File Edit View Insert Cell Help
In (27): # load average wordVec result
with open('avg_vector_vocab', 'w') as file:
    avg_vector = pickle.load(file)

In (28): avg_data = basic_data.copy()

In (29): # select row of average wordVec
for i, row in df.iterrows():
    avg_data[i, 2:] = avg_vector[row['id']]

doc2vec

In (30): # load doc2vec model
model = Doc2Vec.load('word2vec_model/doc2vec')

In (31): doc2vec_data = basic_data.copy()

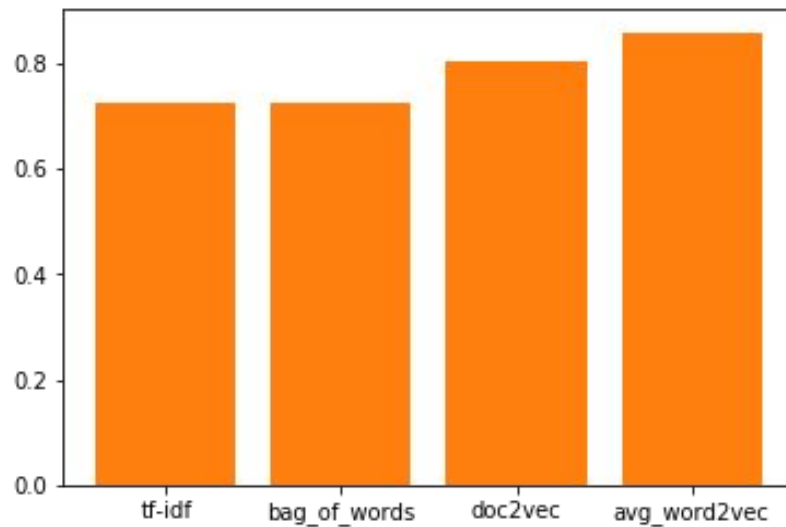
In (32): # select id of doc2vec
for i, row in df.iterrows():
    doc2vec_data[i, 2:] = model.docvecs[row['id']]

prediction model

In (33): from sklearn.model_selection import train_test_split
```



Each model's AUC




程式實作


NLP with RNN

建模流程

Text classification use LSTM



Text classification use LSTM



how to feed text data into LSTM network ?

- 先把 text data 轉換成 id 格式
 - word to id
- 不在 word vector 的字，用別 id 代表
 - e.g. $\text{len}(\text{word})+1$

['韓瑜', '協志', '前妻', '正', '女演員', '周子', '瑜', 'TWICE', '團裡裡面', '台灣', '人', '正', '兩個', '要當', '鄉民', '老婆', '選', '五樓', '真', '勇氣']
[10461, 27588, 84244, 23278, 84491, 90934, 31569, 72550, 100035, 84284, 96798, 23278, 96689, 31004, 62798, 53752, 9
2708, 44764, 66642, 10179, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034,
100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100
034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 10003
4, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034, 100034,
100034, 100034, 100034, 100034, 100034, 100034]



embedding lookup table

```
self.inputs = tf.placeholder(tf.int32, [None, input_length], name='input_data')
self.targets = tf.placeholder(tf.float32, [None, 1], name='targets')
self.bz = tf.placeholder(tf.int32, [], name='batch_size')

## embedding lookup table
em_W = tf.Variable(wv.astype(np.float32), trainable=True)
x = tf.nn.embedding_lookup(em_W, self.inputs)
```



程式練習時間

- 07_rnn_ptt_text_classification.ipynb
 - 練習如何把 text data 轉換成 id 格式
 - 練習建構 embedding lookup table 接 LSTM network
 - 可嘗試
 - fine tune word vector (trainable = True)
 - 不 fine tune word vector (trainable = False)
 - random initialize embedding lookup table



程式實作

BERT fine-tune

歡迎挑戰 kaggle text classification task

- [Toxic Comment Classification Challenge](#)
- [Mercari Price Suggestion Challenge](#)
- [Spooky Author Identification](#)
- [Personalized Medicine: Redefining Cancer Treatment](#)
- [Quora Question Pairs](#)
- ...



還不夠嗎？可以看看別的主題

- N-Gram
 - [Modelling Natural Language with N-Gram Models](#)
 - [自然語言處理中的 N-Gram 模型介紹](#)
- Topic model
 - [Beginner guide to topic modelling in python](#)
 - [Topic modelling with scikit-learn](#)
 - [Latent Dirichlet Allocation](#)
 - [LDA 數學八卦](#)
 - [手刻版 topic model](#)

